


데이터 제작 프로젝트 결과 발표

： 학습 데이터 추가 및 수정을 통한 이미지 속 글자 검출 성능 개선 대회

LV2 CV-18

LIGHT OBSERVER



OUR TEAM



정원국

- # 꾸준한 성장! 어제보다 나은 내일
- # 행동력 있는 Vision 엔지니어



한상준

- # 항상 진심을 다해
- # 끝없는 지속 성장



이동훈

- # 잠은 죽어서...
- # 목표는 AI 엔지니어



전지용

- # 취업과 진학의 경계에..
- # 팀원들과 함께 성장



김형석

- # Vision 엔지니어를 위해
- # End-to-End 경험을!




CONTENTS

1. Competition % Team Mind Set
 2. Competition Strategy
 3. Data Strategy
 4. Training Strategy
 5. Conclusion
-

1. COMPETITION



ABOUT COMPETITION



- 정통 OCR? No
 - Text detection / Text Recognition
 - 결국 text의 영역만 detection
 - 해당 text가 어떠한 글자인지 인식하는 것은 아님
 - model관점이 아닌 data관점에서 성능 개선
- 핵심은 ?
 - Data centric!
 - Continuous Learning

OUR TEAM MIND

- 저번 대회 패착?
 - 시간에 쫓김
 - 그러다 보니 정교한 실험이 이루어지지 못하고 마구잡이식 실험
- 그래서 이번엔?
 - 리더보드 신경쓰지 말고 우리 같길 나아가자 (물론 신경 쓰였지만...)
 - 각자 맡은 역할 열심히 하다보니.. ??

2. COMPETITION STRATEGY



대회 분석

- 제출 방식의 변경
 - Output.csv를 submission 하는 방식에서 Container Snapshot Image를 제출후 AWS SageMaker 에 Deploy 되어 Inference함
 - 평가 데이터는 비공개이며, 따라서 Pseudo labeling 과 같은 기법은 적용할 수 없음
- 협업 환경의 중요성
 - 각자의 환경을 통일하지 않으면 Code sharing 이 불가능 할 것으로 생각하였음
 - Container Snapshot Image가 AWS로 전송되는 과정의 응답성을 높이기 위해 필수 패키지만 설치하고, Conda를 배제함
 - Git / Code sharing Script / WandB / Notion / Slack / Zoom / Google Drive 등을 협업에 필요한 툴을 적극적으로 사용함
- 실험 기록의 중요성
 - Notion에 기록한 개별 실험 기록과 WandB를 통한 Model 성능 비교 결과를 서로 공유하고 함께 분석함
 - 매일 데일리스크럼, 피어세션 시간을 활용하여 서로 의견을 교환하고 필요할 경우 추가 회의를 상시 진행함

구체적 대회 전략

■ Notion을 이용한 협업

- To Do → Request Review → Complete의 흐름으로 서로의 작업 내용을 지속적으로 공유 (또한, 실험 중복을 방지함)
- 실험 결과에 대한 정리를 한 곳에서 볼 수 있도록 함 / 실험 제출 후보를 관리하며 중요도를 판단하여 선택함

To Do

1 backlink

By Engineer By Status Archive Complete 회의록

정원국T41... 3

Notion 작성
P1
Dec 7 → 10

프로젝트 선정
Dec 7 → 9
1

EDA

+ New

Sangjoo... 3

외부 데이터셋 사전 학습
P1
Dec 12 → 13

Datasets 시각화 톨 개발
P2
Dec 7 → 8

Dataset words.values() 없는 경우 터짐
P2

+ New

이동훈(대... 0

+ New

전지용 3

Multiscale inference
P1
Dec 14

Model ensemble
P1
Dec 15

Output visualization
P2
Dec 11 → 12

+ New

Kim Hye... 2

Refine BBox
Dec 13 → 14

inference analysis
Dec 14 → 15

+ New

No ML En... 4

템플릿
P1
Dec 7 → 10

사용 가이드 (임시)
P1

회의 안건 작성
회의
Dec 8

노션 건의 사항

+ New

실험 List

실험 리스트를 정리하는 곳입니다.
- Not Submitted : 제출 예정 없음
- Candidate to submit : 당일 제출 예정
- Submitted : 제출 완료 / Title 에 Public F1 스코어 적어주세요

By Submit Test Table Table

Not Submitted 2

Image Size 2048

FineTuning+GeoAug

+ New

Candidate to submit 2

HierFineTuning2

HierFineTuning

+ New

Submitted 33

HierPretrained(best) + GeoAug -0.6901

MultiScaleInference - 0.6726

SizeUp Inference - 0.6509


HierPretrained(ver1) + GeoAug -0.6718

HierPretrained(ver1) + GeoAug -0.6792(best)


Special thanks to #지구코딩실

구체적 대회 전략

- Git 과 Symbolic link 를 활용한 환경 구성



- Git을 이용한 협업 환경 구성
 - Gitlab-Flow를 실험 환경에 맞도록 변형



구체적 대회 전략

- Symbolic link를 활용하자
 - 항상 Develop 브랜치는 실험 가능한 상태로 유지
 - Symbolic link 를 통해 Merge 의 부담을 최소화하며 팀원간의 실험 공유
- Symbolic link를 활용... 하세요?
 - Uh.. Hmm... Symbolic link요?...
- Symbolic link 당황하지 마세요
 - 헛갈리면 정상입니다.
 - 저희는 "Tool" 이 있으니까요



imgtp.com

JAKE-CLARK.TUMBLR

구체적 대회 전략

- Human Error를 미연에 방지하기 위한 Tool
 - 누구나 헛갈릴 수 있는 Symbolic link를 생성하고 변경해주는 Shell script를 개발
 - 리더보드 제출 Open 하기 전에 모든 환경 구성을 마무리

```
root@c64d752d8f7f: ~/code
-rwxr-xr-x 1 root root 1109 Dec 12 07:51 gen_symlink.sh*
-rwxr-xr-x 1 root root 1846 Dec 12 23:59 sel_symlink.sh*
root@c64d752d8f7f:~/code# ./gen_symlink.sh

EASY Symlink for Light Observer

Usage: ./gen_symlink.sh SOURCE_FILE

ex) ./gen_symlink.sh Txxxx_train_ver2.py
Generated ./develop/train.py ← ./develop/Txxxx_train_ver2.py

root@c64d752d8f7f:~/code# ./sel_symlink.sh

EASY Symlink for Light Observer

Now selected [best_point.pth]

Usage: ./sel_symlink.sh [last | best]

ex) ./sel_symlink.sh best
Changed ./trained_models/latest.pth ← ./trained_models/best_model.pth
Submitting best_model.pth

root@c64d752d8f7f:~/code#
```

[Object Detection] 2022.11.16 ~ 2022.12.01 19:00

mAP (Rank)	개요	생성 시간
0.0000	상세 보기	2022-11-30 23:46
0.0000	상세 보기	2022-11-26 19:52
0.0000	상세 보기	2022-11-26 19:53
0.0000	상세 보기	2022-11-22 21:12
0.0000	상세 보기	2022-11-28 01:15

[Data Annotation] 2022.12.08 ~ 2022.12.15 19:00

f1 (Rank)	recall	precision	개요	생성 시간
0.0779	0.0549	0.1341	상세 보기	2022-12-09 18:57
0.1652	0.1805	0.1523	상세 보기	2022-12-08 23:34
0.2061	0.1808	0.2397	상세 보기	2022-12-13 16:58
0.2187	0.1835	0.2705	상세 보기	2022-12-13 16:19
0.2472	0.1616	0.5251	상세 보기	2022-12-12 08:06
0.2778	0.2053	0.4296	상세 보기	2022-12-10 10:03
0.2778	0.2053	0.4296	상세 보기	2022-12-10 10:08

Human Error Rate 0%



구체적 대회 전략

- 일일 제출 횟수 제한에 대한 고찰
 - 대회 첫날과 대회 마지막 날의 동일한 하루 10번의 제출 기회는 같은 가치를 가지는가?
 - 모델 성능을 필요로 하지 않는 실험은 대회 첫날 하자!

업로드 된 파일 [2022-12-15 18:36] last ensemble ✕

Hyperparameter Training (선택 사항)

--batch_size 100 --learning_rate 0.001

Key	Value
+ input	input

Hyperparameter Inference (선택 사항)

--batch_size 100 --learning_rate 0.001

Key	Value
+ input	input

제출 파일 설명 (선택 사항)

모델에 대한 설명을 1000자 이내로 자유롭게 작성해 주세요.

What?

결과 제출 (남은 횟수: 10 / 10)

Input size를 변경하면?


Batch size를 변경하면?

Model dir를 변경하면?

구체적 대회 전략

- Pretrained model weight 의 중요성
 - 지난 대회를 통해 Pretrained model weight의 중요성을 배움
 - 단, 이번 대회의 경우 Backbone model의 VGG weight만 제공됨
 - 대량의 학습 데이터를 통해 우리의 Pretrained model weight를 만들자
 - Pretrained model weight를 Load 하여 본 대회 데이터로 Fine-tuning 하자
 - 다양한 실험을 빠르게 수 있다
- Candidate External Datasets
 - Camper Dataset ← Annotation 보정 없이 그대로 **전체 사용** / 일부 실험에서 제외하였을 경우도 평가함
 - ICDAR19 MLT ← 학습 시간을 고려하여 **Korean only 최종 채택 (약 1,000장)**
 - ICDAR19 LSVT ← 학습 시간을 고려하여 사용하지 않음
 - ICDAR19 ArT ← 캠퍼 제작 데이터셋과 가장 유사한 Annotation rule을 보였지만 학습 시간을 고려하여 사용하지 않음
 - COCO-Text ← 데이터셋 Annotation rule의 상이함으로 사용하지 않음
 - HierText ← **전체 데이터셋 최종 채택 (약 9,000장)**

3. EXPLORATORY DATA ANALYSIS



DATASETS 분석

- ICDAR2019
 - ArT is a combination of Total-Text [4], SCUT-CTW1500 [5] and Baidu Curved Scene Text, which were collected with the motive of introducing the arbitrary-shaped text problem to the scene text community.
 - 데이터셋 특징
 - 곡선과 원형 패턴의 글자 이미지들이 많이 들어있다.
 - Image size (2000,2000) ~ (4000,4000) 사이의 다양한 사이즈로 구성되어 있다.




DATASETS 분석

■ HierText Dataset

- CVPR 2022 / Towards End-to-End Unified Scene Text Detection and Layout Analysis @Google Research 에서 발표
- Scene Text Detection Task 와 Layout Analysis 을 통합하기 위한 모델과 관련한 논문과 데이터셋을 공개
- 데이터셋 특징
 - 이미지당 평균 **100단어 이상**이며, 현재 가장 밀도가 높은 TextOCR(2021년)보다 두 배 더 밀도가 높음

Dataset	#Img			#Word (avg/total)	Ann Level		
	Train	Val	Test		Word	Line	Paragraph
IC15 [19]	1,000	0	500	4.4/6.5K	✓		
Total-Text [10]	1,255	0	300	7.4/11K	✓		
CTW1500 [60]	1,000	0	500	6.7/10K		✓	
MSRA-TD500 [59]	300	0	200	6.9/3.5K		✓	
IC17 MLT* [38]	7,200	1,800	9,000	9.5/85K	✓		
IC19 MLT* [37]	10,000	0	10,000	8.9/89K	✓		
IC19 LSVT* [49]	30,000	0	20,000	8.1/243K		✓	
IC19 ArT* [11]	5,603	0	4,563	8.9/50K	✓		
TextOCR [48]	21,778	3,124	3,232	32.1/903K	✓		
Intel OCR [22]	191,059	16,731	0	10.0/ 2.1M	✓		
HierText	8,281	1,724	1,634	103.8/1.2M	✓	✓	✓

Table 1. HierText v.s. other datasets. Our dataset is characterized by high text density and hierarchical annotations. Datasets marked with * do not provide test set annotations. The train and validation sets were used to count the number of words.



(c) Text spatial distributions.

Figure 2. **Statistics of HierText dataset.** Compared to other datasets, our dataset has higher word density per image and more uniformly distributed text.

DATASETS 분석

- Camper Dataset
 - 좋은 데이터? 나쁜 데이터?



DATASETS 적용 방법

- JPEG 이미지 메타정보(exif) Orientation 변환




DATASETS 적용 방법

- 다각형 Poly → Rect로 변환



4. TRAINING STRATEGY









학습전략

- Geometric Augmentation
 - Rotate and Crop
 - Rotate : ± 30
 - Random Crop : 20 ~ 100%
- Color Augmentation
 - Color Jitter
 - Brightness : 50 ~ 100%
 - Contrast : 50 ~ 100%
 - Saturation : 50 ~ 100%
 - Hue : 50 ~ 100%
- 버려진 Augmentation
 - Gauss Noise
 - ISO Noise
 - Channel Shuffle
 - CHALE
 - ImageCompression
 - ...


학습전략

■ Augmentation 예시



학습전략

- N times Pre-Trained
 - 기존의 vgg16 가중치와 구축한 데이터셋을 활용하여 더 좋은 학습 가중치를 base로 설정
 - 더 많은 데이터셋을 가지고 학습한 가중치부터 다시 짧게 학습 시작




학습전략

- Multi Scale Inference
 - 입력 이미지의 크기를 다르게 하여 추론된 Bbox를 합침
- Model Ensemble
 - 여러 실험 결과의 장점을 살리고자 앙상블 진행




MODEL TRAINING OVERVIEW

■ Miro diagram



EXPERIMENTS LOGGING

- Wandb



- Notion

Basedata + camperdata - 0.5188

 Person

☰ Datasets

☰ Data strategy

 Status

Val F1

Public F1

 WandB Link

 Submit Date

— L L

13

 이동훈(대학원생-비즈니스IT전공) Dec 11
augmentation 은 없는거죠? 생각보다 기본만 해도 높긴하네요.

 Add a comment...

baseline 코드 그대로 적용

기본 데이터셋과 Camper 데이터셋을 합쳐서 학습 진행

100애평

by Solution	Test Suite	no. Datasets	이벤트	# Public F1	Status	as Person
Baseline OSG - 0.1349	ICDAR17_Jorhan			0.140	Submitted	Sanggon Han
Baseline + compenator - 0.5108 (1)	Camper ICDAR17_Jorhan			0.188	Accepted	전지희
Base + Adversal X (1) 0.6124	ICDAR17_Jorhan				Submitted	이종호(이국영팀 보조)
onlycamper				0.0779	Submitted	Kim HyungSeok
onlycamper 200epoch				0.2263	Submitted	Kim HyungSeok
Image Size 2048					Not Submitted	Sanggon Han
Baseline OSG - 0.3677	ICDAR17_Jorhan			0.3877	Submitted	Sanggon Han
Param Test - 0.1652	ICDAR17_Jorhan				Submitted	Sanggon Han
Noise_OSD	Camper			0.3	Submitted	정창욱(4199)
NoAug Best	Camper ICDAR17_Jorhan			0.319	Submitted	Kim HyungSeok
NoAug Last	Camper ICDAR17_Jorhan			0.6121	Submitted	Kim HyungSeok
F1 Score Test - 0.2472	ICDAR17_Jorhan			0.2472	Submitted	Sanggon Han
MemPatches + smatAug - 0.5107	Camper ICDAR17_Jorhan			0.2024	Submitted	이종호(이국영팀 보조)
BackAug + Hard Rotation	Camper ICDAR17_Jorhan			0.2021	Submitted	Kim HyungSeok
Finetuning-GesAug			inference inputSize=1512	0.3919	Submitted	Kim HyungSeok
Finetuning-GesAug			inference inputSize=1024	-0.7	Submitted	Kim HyungSeok
Finetuning-GesAug			inference inputSize=2048	0.127	Submitted	Kim HyungSeok
Finetuning-GesAug			inference inputSize=1024	0.042	Submitted	Kim HyungSeok
Finetuning-GesAug	Camper ICDAR17_Jorhan		Train inputSize=1024 U/a=4-100 epoch, Best		Not Submitted	Kim HyungSeok
Finetuning-GesAug	Camper ICDAR17_Jorhan		Train inputSize=1024 U/a=4-100 epoch, Best	0.197	Submitted	Kim HyungSeok
Finetuning-GesAug	Camper ICDAR17_Jorhan		Train inputSize=1024 inference inputSize=2048 U/a=4-100 epoch, Best	0.0556	Submitted	Kim HyungSeok
MemPatches+TDA+0.4 - 0.429	HotTest ICDAR17_Jorhan			0.429	Submitted	전지희
Finetuning+7719 dataset - best aug				0.5462	Submitted	Kim HyungSeok
MemPatches+7719_best.m odel				0.092	Submitted	Kim HyungSeok
Retained for MemPatches - 0.1319	Camper ICDAR17_Jorhan ICDAR19_Ju			0.1390	Submitted	Sanggon Han
Finetuning best	ICDAR17_Jorhan ICDAR19_Jorhan			0.0615	Submitted	Kim HyungSeok
HotTestAug	ICDAR17_Jorhan ICDAR19_Jorhan		no aug.	0.0615	Submitted	Kim HyungSeok
HotTestAug			aug		Candidate to Submit	Kim HyungSeok
HotTestAug2			aug		Candidate to Submit	Kim HyungSeok
Stochy Inference - 0.618	Camper ICDAR17_Jorhan ICDAR19_Ju		Input Size = 2048	0.6109	Submitted	전지희
MultiScaleInference - 0.6126	Camper ICDAR17_Jorhan ICDAR19_Ju		Input Size Inference (1024, 2048)	0.6021	Submitted	전지희
HotTestInference2 + GesAug - 0.5051	ICDAR17_Jorhan ICDAR19_Jorhan Cam			0.001	Submitted	Kim HyungSeok
HotTestInference2 + GesAug - 0.4733(best)	ICDAR17_Jorhan ICDAR19_Jorhan Cam			0.0762	Submitted	전지희
HotTestInference2 + GesAug17	ICDAR17_Jorhan ICDAR19_Jorhan Cam			0.0717	Submitted	전지희
Model Ensemble17 - 0.6677	ICDAR17_Jorhan ICDAR19_Jorhan Cam		Model ensemble	0.0818	Submitted	Sanggon Han
HotTestInference2 + GesAug + Camper - 0.6784	ICDAR17_Jorhan ICDAR19_Jorhan			0.0764	Submitted	Sanggon Han
Model Ensemble + 0.668	ICDAR17_Jorhan ICDAR19_Jorhan Cam		Model Ensemble	0.0583	Submitted	전지희 Sanggon Han

RESULT VISUALIZATION



5. CONCLUSION



대회를 통해 성장한 점

■ 결론

- 대회 분석에서 예상한 바와 같이 AI 모델 학습에서 데이터가 얼마나 중요한지 경험을 통해 알게 됨
- 강건한 모델은 좋은 데이터로부터 만들 수 있음
- 특히 이번 대회는, HierText dataset을 통해 일반화 성능을 높인것이 Public rank 6위에서 Private rank 1위를 할 수 있게 만들어 주었다고 판단
- 적은 데이터로 높은 성능을 냄

순위	팀 이름	팀 멤버	f1 ↕	recall ↕	precision ↕	제출 횟수	최종 제출
1 (5 ▲)	CV_18조		0.7200	0.6506	0.8060	40	17h
1	CV_18조		0.7200	0.6506	0.8060	40	17h
2	CV_16조		0.7192	0.6321	0.8341	43	1d
3	CV_14조		0.7174	0.6324	0.8288	51	18h
4	CV_13조		0.7034	0.6081	0.8340	35	2d
5	CV_02조		0.6959	0.6002	0.8279	42	19h

■ 성장 포인트 회고

- 데이터의 중요성! 협업의 중요성! 부캠 내에는 도움을 주고 싶은 사람이 많습니다
- 대회는 대회일뿐... 차근차근 정한 방향으로 나아가면 결과는 따라올 것이라 생각합니다
- 포기하지 않고 도전하니, 어제의 나보다 성장해있었다.
- 이번 대회를 통해 여러 사람과 함께 협업할 수 있는 AI Engineer로 성장해가고 있음을 느꼈습니다. CV-18 팀워크 최고!

One more thing...

기도 버프...

한상준_T4226 Yesterday at 1:30 PM
 마지막 부스팅!!!
 gogogogo.png



5 👍 7 🗣️ 3 🙏 5 🔄

6 replies

한상준_T4226 22 hours ago
 본인 또는 지인이 인터넷 도박 등의 문제가 있는 것을 알게 되는 경우에는 [한국도박문제관리센터 홈페이지 \(www.kcgp.or.kr\)](http://www.kcgp.or.kr) 또는 상담전화(☎️ 1336)를 통해 상담신청을 하시면 도움을 받으실 수 있습니다.


홍인희_T4232 22 hours ago
 ㅋㅋㅋㅋㅋㅋㅋㅋㅋㅋㅋㅋㅋㅋ 재밌네요

성예담_멘토 22 hours ago
 기도메타..

한상준_T4226 21 hours ago
 🙏

유정호_T4138 21 hours ago
 떡상을 기원합니다! 🔥 🙏

고현욱_T4007 21 hours ago
 기영이에겐 낭만이 있다.



당신의 곁에는 같이 기도해 줄 부스트캠퍼들,
 운영진과 멘토, 조교분들이 있습니다.
 Slack으로 고민과 어려움을 같이 공유해보아요!
 기꺼이 원기옥을 모아줄겁니다

BOOSTCAMP: 지속 가능한 성장을 위한 학습 커뮤니티

- “등수는 상관없다”가 승자의 여유나 패자의 변명이 아님에 꼭 공감해주시길 바랍니다.
 - “승패”가 아닌 자신의 랩업을 위해 Wrap up 잘해서 Level up 하세요!
 - 이번 대회는, 짧은 기간이었던만큼 더 빠른 패스를 찾게된 “운”도 강하게 작용 했을것입니다.
 - 물론 그 운을 만들어내기 위해 노력한, 특히 부상투혼을 보여준 동훈님, 원국님께 박수를!!
- CV Track 여러 캠퍼분들 그리고 NLP트랙팀과 함께 “지속 가능한 학습 커뮤니티”에 대해 고민하고 있습니다.
- 지속 성장이 필요한 이유 (feat. 중꺂마)
 - 신(또는 양자역학)의 장난으로 노력의 결과는 동일한 속도로 돌아오지 않아요.
 - 원하는 결과가 눈 앞에 보이지 않아도, 더 멀리서 나에게 다가오고 있습니다.
- Slack #Level_Track_질의응답 게시판에 답이 있습니다!
 - 질문을 하면, 누군가 나타나 도움을 줍니다. 도움을 받아보세요!
 - 답변을 하면, 나에게도 도움이 됩니다. 복습 효과와 내가 아는 답이 맞는지 체크받을 수 있습니다!